

UNIVERZA V LJUBLJANI
FAKULTETA ZA MATEMATIKO IN FIZIKO

Finančna matematika – 1. stopnja

Anej Rozman

Sestavljeni Poissonov proces in njegova uporaba v financah

Delo diplomskega seminarja

Mentor: doc. dr. Martin Raič

Ljubljana, 2024

KAZALO

1. Uvod	5
2. Sestavljena Poissonova porazdelitev	6
2.1. Porazdelitev	6
2.2. Rodovne funkcije	7
3. Sestavljeni Poissonov proces	9
3.1. Osnovne lastnosti	9
3.2. Martingali	11
3.3. Časi ustavljanja in lastnosti Markova	12
3.4. Neskončna deljivost	12
4. Cramér-Lundbergov model	14
4.1. Proces tveganja in verjetnost propada	14
4.2. Lahkorepe porazdelitve	18
4.3. Težkorepe porazdelitve	27
5. Priloga	30
Slovar strokovnih izrazov	34
Literatura	34

Sestavljeni Poissonov proces in njegova uporaba v financah

POVZETEK

V prvem delu diplome najprej definiramo splošen slučajni proces v zveznem času in osnovne lastnosti, ki jih študiramo. Nato definiramo sestavljeno Poissonovo porazdelitev in obravnavamo njeno porazdelitveno funkcijo ... Definiramo sestavljeni Poissonov proces in dokažemo neodvisnost in stacionarnost prirastkov, pogoj, da je proces martingal, šibko in krepko lastnost Markova in pokažemo, da je gradnik neskončno deljivih procesov ti. Lévijskih procesov. V drugem delu diplome obravnavamo aplikacijo sestavljenega Poissonovega procesa v Cramér–Lundbergovem modelu. Definiramo verjetnost propada in obravnavamo njeno obnašanje v odvisnosti od začetnega kapitala. Dokažemo Lundbergovo neenakost in asimptotično obnašanje verjetnosti propada, ko zahtevke modeliramo z lažkorepo in težkorepo porazdelitvijo. Obnašanje verjetnosti propada na koncu praktično prikažemo z večkratnim simuliranjem procesa tveganja.

Compound Poisson process and its application in finance

ABSTRACT

In the first part of the diploma, we first define a general stochastic process in continuous time and basic properties that we study. We then define the compound Poisson distribution and consider its distribution function ... We define the compound Poisson process and prove the independence and stationarity of the increments, the condition under which the process is a martingale, the weak and strong Markov property, and show that it is a building block of infinitely divisible processes, i.e. Lévy processes. In the second part of the diploma, we consider the application of the compound Poisson process in the Cramér–Lundberg model. We define the probability of ruin and consider its behavior depending on the initial capital. We prove the Lundberg inequality and the asymptotic behavior of the probability of ruin when claims are modeled with light-tailed and heavy-tailed distributions. We practically demonstrate the behavior of the probability of ruin at the end with repeated simulation of the risk process.

Math. Subj. Class. (2020): 60G07 60G20 60G51

Ključne besede: slučajni procesi, sestavljena Poissonova porazdelitev, sestavljeni Poissonov proces, martingal, šibka lastnost Markova, krepka lastnost Markova, neskončna deljivost, Cramér–Lundbergov model, lahkorepa porazdelitev, težkorepa porazdelitev


Keywords: stochastic processes, compound Poisson distribution, compound Poisson process, martingale, weak Markov property, strong Markov property, infinite divisibility, Cramér–Lundberg model, light-tailed distribution, heavy-tailed distribution

ZAHVALA

V nastajanju :)

1. UVOD

Uvodni tekst in motivacija za študiranje procesa, nakaži da boš obravnaval Cramer-Ludenbergov model



SLIKA 1. Primer trajektorije sestavljenega Poissonovega procesa

Definicija 1.1. Naj bo $(\Omega, \mathcal{F}, \mathbb{P})$ verjetnostni prostor in naj bo $T \neq \emptyset$ neprazna indeksna množica ter (E, Σ) merljiv prostor. *Slučajni proces*, parametriziran s T , je družina slučajnih elementov $X_t : \Omega \rightarrow E$, ki so (\mathcal{F}, Σ) -merljivi za vsak $t \in T$.

Opomba 1.2. V delu se bomo omejili na primer, ko T predstavlja čas, torej $T = [0, \infty)$ in da slučajne spremenljivke zavzemajo vrednosti v realnih številih, torej $(E, \Sigma) = (\mathbb{R}, \mathcal{B}_{\mathbb{R}})$, kjer $\mathcal{B}_{\mathbb{R}}$ predstavlja Borelovo σ -algebro na \mathbb{R} .

Definicija 1.3. Za fiksni $\omega \in \Omega$ je preslikava $[0, \infty) \rightarrow \mathbb{R}; t \mapsto X_t(\omega)$ *trajektorija* oziroma *realizacija* slučajnega procesa $(X_t)_{t \geq 0}$. Tako lahko slučajni proces gledamo kot predpis, ki vsakemu elementu vzorčnega prostora Ω priredi slučajno funkcijo $(X_t(\omega))_{t \geq 0} : [0, \infty) \rightarrow \mathbb{R}$.

Definicija 1.4. Naj bo $(X_t)_{t \geq 0}$ slučajni proces. Potem za $s < t$ definiramo *prirastek procesa* $X_t - X_s$ na intervalu $[s, t]$. Proces $(X_t)_{t \geq 0}$ ima *neodvisne prirastke*, če so za vsak nabor realnih števil $0 \leq t_1 < t_2 < \dots < t_n < \infty$ prirastki

$$X_{t_2} - X_{t_1}, X_{t_3} - X_{t_2}, \dots, X_{t_n} - X_{t_{n-1}}$$

med seboj neodvisni.

Definicija 1.5. Naj bo $(X_t)_{t \geq 0}$ slučajni proces. Potem pravimo, da ima proces *stacionarne prirastke*, če za vsak $s < t$ in vsak $h > 0$ velja, da ima $X_{t+h} - X_{s+h}$ enako porazdelitev kot $X_t - X_s$.

Definicija 1.6. Naj bo $\lambda > 0$. Slučajnemu procesu $(N_t)_{t \geq 0}$, definiranim na verjetnostnem prostoru $(\Omega, \mathcal{F}, \mathbb{P})$ z vrednostmi v \mathbb{N}_0 , pravimo *Poissonov proces* z intenzivnostjo λ , če zadošča naslednjim pogojem:

- (1) $N_0 = 0$ \mathbb{P} -skoraj gotovo.
- (2) $(N_t)_{t \geq 0}$ ima neodvisne in stacionarne prirastke,
- (3) Za $0 \leq s < t$ velja $N_t - N_s \sim \text{Pois}(\lambda(t - s))$,

Opomba 1.7. Vidimo, da v definiciji ne zahtevamo, da so skoki procesa le $+1$. To sledi iz...

2. SESTAVLJENA POISSONOVA PORAZDELITEV

Definicija 2.1. Naj bo $N \sim \text{Pois}(\lambda)$ za $\lambda > 0$ in X_1, X_2, \dots zaporedje neodvisnih (med seboj in N) enako porazdeljenih slučajnih spremenljivk. Potem pravimo, da ima slučajna spremenljivka

$$S = \sum_{i=1}^N X_i$$

sestavljeno Poissonovo porazdelitev.

2.1. Porazdelitev. S pogojevanjem na $N = n$ pridemo do formule za porazdelitev S . Za $x \in \mathbb{R}$ velja

$$\begin{aligned} F_S(x) &= \mathbb{P}(S \leq x) = \sum_{n=0}^{\infty} \mathbb{P}(S \leq x \mid N = n) \mathbb{P}(N = n) \\ &= \sum_{n=0}^{\infty} \mathbb{P}\left(\sum_{i=1}^n X_i \leq x\right) \mathbb{P}(N = n) \\ &= \sum_{n=0}^{\infty} F_{X_1}^{*n}(x) \frac{\lambda^n}{n!} e^{-\lambda} \end{aligned}$$

kjer je $F_{X_1}^{*k}(x)$ porazdelitev k -te konvolucije slučajne spremenljivke X_1 .

Zgled 2.2. Poglejmo enega enostavnejših primerov, ko so X_1, X_2, \dots porazdeljene kot

$$X_1 \sim \text{Exp}(a) \quad f_{X_1}(x) = ae^{-ax} \mathbb{1}_{(0, \infty)}(x),$$

s parametrom $a > 0$. Vemo, da je k -ta konvolucija X_1 porazdeljena kot $\text{Gamma}(k, a)$ in ima gostoto

$$f_{X_1 + \dots + X_k}(x) = \frac{1}{\Gamma(k)} a^k x^{k-1} e^{-ax} \mathbb{1}_{(0, \infty)}(x).$$

Za $s > 0$ velja

$$\begin{aligned} F_S(s) &= \sum_{k=0}^{\infty} \int_0^s \frac{1}{\Gamma(k)} a^k x^{k-1} e^{-ax} dx \frac{(\lambda)^k}{k!} e^{-\lambda} && \text{Tonelli (5.10)} \\ &= \int_0^s \underbrace{\sum_{k=0}^{\infty} \frac{1}{(k-1)!k!} (a\lambda)^k x^{k-1} e^{-(ax+\lambda)}}_{f_S(x)} dx. \end{aligned}$$

Vidimo, da že v primeru, ko poznamo eksplcitno formulo za $F_{X_1}^{*k}$, težko pridemo do kakršne koli porazdelitve S v končni obliki. V praksi se zato poslužujemo numeričnega ocenjevanja porazdelitve. \diamond

2.2. Rodovne funkcije.

Trditev 2.3. *Naj bo $N \sim \text{Pois}(\lambda)$ za $\lambda > 0$ in X_1, X_2, \dots zaporedje neodvisnih (med seboj in N) enako porazdeljenih slučajnih spremenljivk s karakteristično funkcijo φ_{X_1} . Potem ima za $u \in \mathbb{R}$ karateristična funkcija $S = \sum_{i=1}^N X_i$ obliko*

$$\varphi_S(u) = e^{\lambda t(\varphi_{X_1}(u)-1)}.$$

Dokaz.

$$\begin{aligned} \varphi_S(u) &= \mathbb{E}[\exp[iuS]] = \mathbb{E}\left[\exp\left[iu \sum_{i=1}^N X_i\right]\right] \\ &= \sum_{k=0}^{\infty} \mathbb{E}\left[\exp\left[iu \sum_{i=1}^N X_i \mid N = k\right]\right] \mathbb{P}(N = k) \\ &= \sum_{k=0}^{\infty} \mathbb{E}\left[\exp\left[iu \sum_{i=1}^k X_i\right]\right] \mathbb{P}(N = k) \\ &= \sum_{k=0}^{\infty} \underbrace{\mathbb{E}[e^{iuX}]^k}_{\varphi_{X_1}(u)^k} \frac{(\lambda t)^k}{k!} e^{-\lambda t} \\ &= e^{-\lambda t} + e^{-\lambda t} \sum_{k=1}^{\infty} \frac{(\varphi_{X_1}(u)\lambda t)^k}{k!} \\ &= e^{\lambda t(\varphi_{X_1}(u)-1)} \end{aligned} \tag{1}$$

\square

Hitro lahko vidimo, sta rodovna in momentno rodovna funkcija S enaki

$$\varphi_S(u) = e^{\lambda t(\varphi_{X_1}(u)-1)} \quad \text{in} \quad G_S(u) = e^{\lambda t(G_{X_1}(u)-1)},$$

saj v splošnem velja, da je karakteristična funkcija neke slučajne spremenljivke Y enaka njeni momentno rodovni funkciji iz vrednoteni v iu , torej $\varphi_Y(u) = G_Y(iu)$. Rodovna pa izverdnjena v $\ln(u)$, torej $G_Y(u) = M_Y(\ln(u))$, če obstajata. V nadaljevanju bomo uporabljali predvsem karakteristično funkcijo CPP , saj je ta vedno definirana za vsak $u \in \mathbb{R}$. Prav nam bo prišla tudi naslednja povezava med karakteristično funkcijo CPP in rodovno funkcijo $HPP(\lambda)$.

Trditev 2.4. *Naj bosta $(S_t)_{t \geq 0}$ CPP in $(N_t)_{t \geq 0}$ $HPP(\lambda)$ neodvisna. Naj bodo slučajne spremenljivke X_i , ki jih seštevamo v CPP enako porazdeljene kot X . Potem za fiksen $t \geq 0$ velja*

$$\varphi_{S_t}(u) = G_{N_t}(\varphi_X(u)).$$

Dokaz. Po enačbi (1) iz trditve 2.3 velja, da je $\varphi_{S_t}(u)$ enaka

$$\begin{aligned}\varphi_{S_t}(u) &= \sum_{k=0}^{\infty} \varphi_X(u)^k \frac{(\lambda t)^k}{k!} e^{-\lambda t} \\ &= G_{N_t}(\varphi_X(u)).\end{aligned}$$

□

Trditev 2.5. Naj bo $N \sim \text{Pois}(\lambda)$ za $\lambda > 0$ in X_1, X_2, \dots, X_n neodvisne s.s. (neodvisne med sabo in od N) enako porazdeljene kot

$$X \sim \begin{pmatrix} a_1 & a_2 & a_3 \dots \\ \frac{\lambda_1}{\lambda} & \frac{\lambda_2}{\lambda} & \frac{\lambda_3}{\lambda} \dots \end{pmatrix},$$

kjer $(a_n)_{n \in \mathbb{N}}$ je poljubno zaporedje realnih števil in $(\lambda_n)_{n \in \mathbb{N}}$ zaporedje pozitivnih realnih števil za katerega velja $\sum_{i=1}^{\infty} \lambda_i = \lambda$. Potem velja

$$\sum_{j=1}^{\infty} a_j Y_j \sim \sum_{j=1}^N X_j,$$

kjer so Y_1, Y_2, \dots neodvisne slučajne spremenljivke porazdeljene kot $\text{Pois}(\lambda_1), \text{Pois}(\lambda_2), \dots$

Dokaz. S $\varphi_{Z_n}(u)$ označimo karakteristično funkcijo slučajne spremenljivke $Z_n := a_1 Y_1 + a_2 Y_2 + \dots + a_n Y_n$ in s $\varphi_Z(u)$ karakteristično funkcijo $Z := \sum_{j=1}^N X_j$. Po neodvisnosti velja

$$\begin{aligned}\varphi_{Z_n}(u) &= \prod_{j=1}^n \varphi_{Y_j}(a_j u) \\ &= \prod_{j=1}^n \exp[\lambda_j (e^{a_j i u} - 1)] \\ &= \exp \left[\sum_{j=1}^n \lambda_j (e^{a_j i u} - 1) \right].\end{aligned}$$

Po trditvi 2.4 velja

$$\begin{aligned}\varphi_Z(u) &= G_N(\varphi_X(u)) \\ &= \exp[\lambda(\varphi_X(u) - 1)] \\ &= \exp \left[\lambda \left(\sum_{j=1}^{\infty} \frac{\lambda_j}{\lambda} e^{a_j i u} - 1 \right) \right] \\ &= \exp \left[\sum_{j=1}^{\infty} \lambda_j (e^{a_j i u} - 1) \right]\end{aligned}$$


Vidimo, da za vsak $u \in \mathbb{R}$ $\varphi_{Z_n}(u)$ po točkah konvergira k $\varphi_Z(u)$, torej

$$\varphi_{Z_n} \xrightarrow{n \rightarrow \infty} \varphi_Z.$$

Po Lévijevem izreku o kontinuiteti (5.7) velja $Z_{\infty} := \lim_{n \rightarrow \infty} Z_n \sim Z$.

□

Kaj pa v primeru, ko so X_i zvezno porazdeljene? Tedaj se problema lotimo na sledeč način. Definiramo $F_n(x) := F(\frac{m}{n})$ kjer je $F(x)$ porazdelitvena funkcija slučajne spremenljivke Z_n in $m = \min\{k \in \mathbb{Z} \mid \frac{k}{n} > F_n(x)\}$.



SLIKA 2. Aproksimacija F s F_n

Kot je razvidno iz slike 2, je $F_n(x)$ stopničasta funkcija, ki aproksimira porazdelitveno funkcijo $F(x)$. Velja $F_n \xrightarrow{n \rightarrow \infty} F$ povsod kjer je F zvezna.

3. SESTAVLJENI POISSONOV PROCES

Povzetek poglavja/krajsi uvod

Definicija 3.1. Naj bo $(N_t)_{t \geq 0}$ Poissonov proces z intenzivnostjo λ . Naj bo $(X_i)_{i \geq 1}$ zaporedje neodvisnih (med sabo in $(N_t)_{t \geq 0}$) in enako porazdeljenih slučajnih spremenljivk z vrednostmi v \mathbb{R} . Potem je *sestavljeni Poissonov proces* $(S_t)_{t \geq 0}$ definiran kot

$$S_t = \sum_{i=1}^{N_t} X_i.$$

Opomba 3.2. Vidimo, da je sestavljeni Poissonov proces posplošitev homogenega Poissonovega procesa, saj če za X_i vzamemo konstantno funkcijo $X_i = 1$ za vsak i , dobimo ravno *HPP*. Bolj v splošnem, če za X_i postavimo $X_i = \alpha$, potem velja $S_t = \alpha N_t$.

V nadaljevanju bomo homogen Poissonov proces z intenzivnostjo $\lambda > 0$ označevali s *HPP*(λ) ali naborom slučajnih spremenljivk $(N_t)_{t \geq 0}$ (angl. Homogeneous Poisson Process), sestavljeni Poissonov proces pa s *CPP* ali naborom slučajnih spremenljivk $(S_t)_{t \geq 0}$ (angl. Compound Poisson Process), kjer bo vsota sledila *HPP*(λ).

3.1. Osnovne lastnosti.

Trditev 3.3. Naj bo $(X_t)_{t \geq 0}$ slučajni proces na $(\Omega, \mathcal{F}, \mathbb{P})$. Potem ima $(X_t)_{t \geq 0}$ neodvisne prirastke natanko tedaj, ko je za vsak nabor realnih števil $0 \leq t_1 < \dots < t_n < t_{n+1} < \infty$ prirastek $X_{t_{n+1}} - X_{t_n}$ neodvisen od slučajnega vektorja $(X_{t_1}, \dots, X_{t_n})$.

Dokaz. (\Rightarrow) :
 (\Leftarrow) :

□

Trditev 3.4. *CPP ima neodvisne in stacionarne prirastke.*

Dokaz. Za nabor realnih števil $0 \leq t_1 < t_2 < \dots < t_n < \infty$ lahko slučajne spremeljivke $S_{t_i} - S_{t_{i-1}}$ zapišemo kot

$$S_{t_i} - S_{t_{i-1}} = \sum_{j=N_{t_{i-1}}+1}^{N_{t_i}} X_j.$$

Neodvisnost prirastkov sledi po neodvisnosti X_i od X_j za $i \neq j$ in N_t . Naj bo $h > 0$ in $s < t$. Potem velja

$$S_{t+h} - S_{s+h} = \sum_{j=N_{s+h}+1}^{N_{t+h}} X_j$$

Vsota ima $N_{t+h} - N_{s+h}$ členov. Ker za HPP velja $N_{t+h} - N_{s+h} \sim N_t - N_s$, je

$$\sum_{j=N_{s+h}+1}^{N_{t+h}} X_j = \sum_{j=N_s+1}^{N_t} X_j = S_t - S_s.$$

□

Trditev 3.5. *Naj bo $(S_t)_{t \geq 0}$ CPP in naj bosta $\mu = \mathbb{E}[X_i] < \infty$ pričakovana vrednost in $\sigma^2 = \text{Var}[X_i] < \infty$ varianca slučajnih spremenljivk X_i za vsak i . Potem sta za $t \geq 0$ pričakovana vrednost in varianca S_t enaki*

$$\mathbb{E}[S_t] = \mu\lambda t \quad \text{in} \quad \text{Var}[S_t] = \lambda t (\sigma^2 + \mu^2).$$

Dokaz. Definiramo slučajno spremenljivko

$$Y_k = X_1 + X_2 + \dots + X_k \tag{2}$$

in vidimo, da je za $t \geq 0$ S_t pogojno na $N_t = k$ enako porazdeljena kot Y_k . Tako dobimo

$$\mathbb{E}[S_t \mid N_t = k] = \mathbb{E}[Y_k] = k\mu \quad \text{in} \quad \text{Var}[S_t \mid N_t = k] = \text{Var}[Y_k] = k\sigma^2.$$

Po formuli za popolno pričakovano vrednost velja $\mathbb{E}[S_t] = \mathbb{E}[\mathbb{E}[S_t \mid N_t]]$. Torej

$$\mathbb{E}[S_t] = \mathbb{E}[\mathbb{E}[S_t \mid N_t]] = \mathbb{E}[\mu N_t] = \mu\lambda t.$$

Prek formule $\text{Var}[S_t] = \mathbb{E}[\text{Var}[S_t \mid N_t]] + \text{Var}[\mathbb{E}[S_t \mid N_t]]$ računamo

$$\mathbb{E}[\text{Var}[S_t \mid N_t]] = \mathbb{E}[\text{Var}[X_i \mid N_t]] = \sigma^2 \lambda t$$

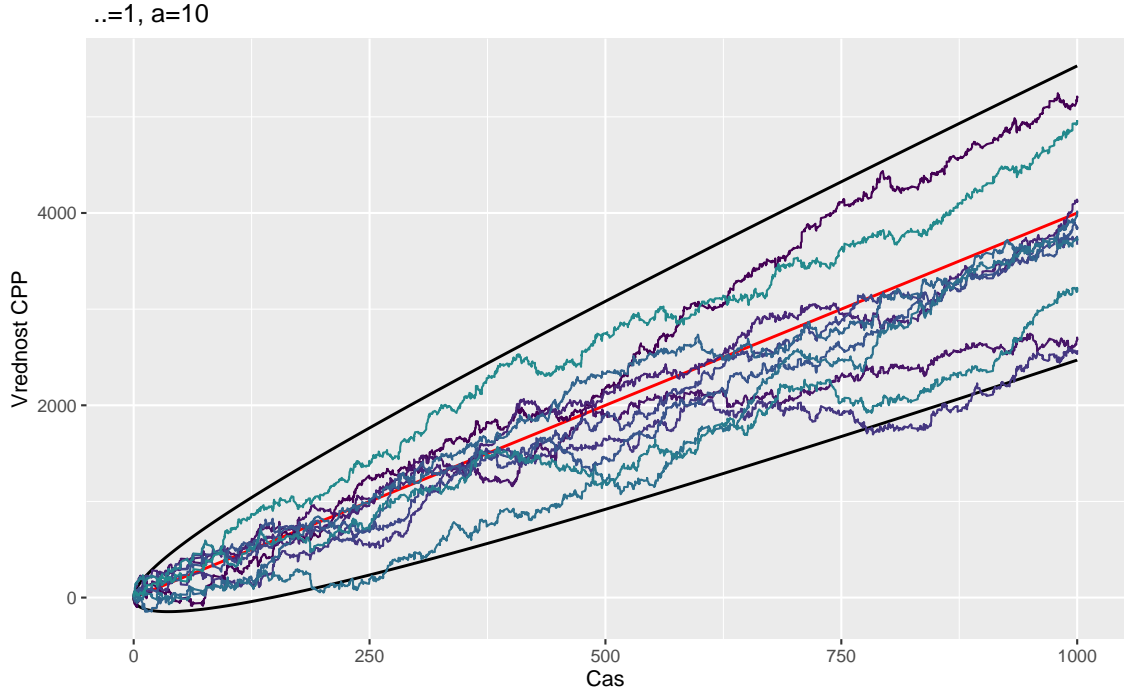
in

$$\text{Var}[\mathbb{E}[S_t \mid N_t]] = \text{Var}[\mathbb{E}[X_i \mid N_t]] = \mu^2 \lambda t,$$

saj $N_t \sim \text{Pois}(\lambda t)$. Skupaj dobimo $\text{Var}[S_t] = \lambda t (\sigma^2 + \mu^2)$.

□

Zgled 3.6. Poglejmo si konkreten primer



SLIKA 3. Trajektorije CPP z VarX in EX

◇

3.2. Martingali.

Definicija 3.7. Slučajni proces X_t prilagojen glede na filtracijo $(\mathcal{F}_t)_{t \geq 0}$ martingal, če velja

$$\mathbb{E}[X_t | \mathcal{F}_s] = X_s$$

za vsak $0 \leq s \leq t$.

Pokažimo, da v splošnem CPP ni martingal.

Trditev 3.8. Naj bo $(S_t)_{t \geq 0}$ CPP z intenzivnostjo $\lambda > 0$ in naj bodo X_i neodvisne in enako porazdeljene slučajne spremenljivke z $\mathbb{E}[X_i] = \mu$ za vsak i . Potem je S_t martingal natanko tedaj, ko je $\mu = 0$.

Dokaz. Naj bo $0 \leq s \leq t$. Potem velja

$$\begin{aligned} \mathbb{E}[S_t | \mathcal{F}_s] &= \mathbb{E}[S_t - S_s + S_s | \mathcal{F}_s] \\ &= \mathbb{E}[S_t - S_s] + \mathbb{E}[S_s | \mathcal{F}_s] \\ &= \mu\lambda(t - s) + S_s \end{aligned}$$

Enakost $\mu\lambda(t - s) + S_s = S_s$ velja $\iff \mu\lambda(t - s) = 0 \iff \mu = 0$. □

Opomba 3.9. Seveda, če velja $\mu \geq 0$, potem je S_t submartingal, če pa $\mu \leq 0$, je S_t supermartingal.

Trditev 3.10. Naj bo $(S_t)_{t \geq 0}$ CPP z intenzivnostjo $\lambda > 0$ in naj bodo X_i neodvisne in enako porazdeljene slučajne spremenljivke z $\mathbb{E}[X_i] = \mu$ za vsak i , Potem je proces

$$S_t - \mu\lambda t$$

martingal.

Dokaz. Naj bosta $0 \leq s < t$. Prirastek $S_t - S_s$ je neodvisen od \mathcal{F}_s in ima pričakovano vrednost $\mu\lambda(t - s)$. Torej

$$\begin{aligned}\mathbb{E}[S_t - \mu\lambda t \mid \mathcal{F}_s] &= \mathbb{E}[S_t - S_s] + S_s - \mu\lambda t \\ &= \mu\lambda(t - s) + S_s - \mu\lambda t \\ &= S_s - \mu\lambda s.\end{aligned}$$

□

3.3. Časi ustavljanja in lastnosti Markova.

3.4. Neskončna deljivost.

Definicija 3.11. Naj bo X slučajna spremenljivka. Pravimo, da je X *neskončno deljiva*, če za vsak $n \in \mathbb{N}$ obstajajo neodvisne slučajne spremenljivke X_1, X_2, \dots, X_n tako, da velja

$$X \sim X_1 + X_2 + \dots + X_n.$$

Ekvivalento lahko definiramo neskončno deljivost prek karakteristične funkcije. Pravimo, da je slučajna spremenljivka X neskončno deljiva, če je za vsak $n \in \mathbb{N}$ funkcija $(\varphi_X(u))^{\frac{1}{n}}$ karakteristična funkcija neke slučajne spremenljivke.

Zgled 3.12. Naj bo $X \sim \text{Pois}(\lambda)$. Potem je X neskončno deljiva. To neposredno sledi iz dejstva, da je karakteristična funkcija vsote n.e.p. s.s. enaka produktu karakterističnih funkcij, torej za $n \in \mathbb{N}$ in $u \in \mathbb{R}$ velja $\varphi_{X_1+X_2+\dots+X_n}(u) = \varphi_X(u)^n$. Če vzamemo $X_i \sim \text{Pois}(\frac{\lambda}{n})$, potem je

$$\varphi_{X_1+X_2+\dots+X_n}(u) = (\varphi_{X_i}(u))^n = \left(e^{\frac{\lambda}{n}(e^{iu}-1)}\right)^n = e^{\lambda(e^{iu}-1)} = \varphi_X(u).$$

◇

Sedaj pokažimo, da je sestavljena Poissonova porazdelitev neskončno deljiva, še več, pokažimo, da če je S neskončno deljiva slučajna spremenljivka in zavzema vrednosti v \mathbb{N}_0 , potem ima sestavljeno Poissonovo porazdelitev.

Trditev 3.13. Naj bo S slučajna spremenljivka, porazdeljena sestavljeno Poissonovo s parametrom $\lambda > 0$. Potem je S neskončno deljiva.

Dokaz. Zapišimo $S = \sum_{i=1}^N X_i$, kjer so X_i neodvisne in enako porazdeljene slučajne spremenljivke s skupno karakteristično funkcijo $\varphi_X(u)$ in $N \sim \text{Pois}(\lambda)$. Iz trditve 2.3 vemo, da je karakteristična funkcija S za $u \in \mathbb{R}$ enaka

$$\varphi_S(u) = \varphi_N(\varphi_X(u)) = e^{\lambda(\varphi_X(u)-1)}.$$

Potem za $n \in \mathbb{N}$ velja

$$\varphi_S(u) = \left(e^{\frac{\lambda}{n}(\varphi_X(u)-1)}\right)^n$$

in vidimo, da je funkcija $u \mapsto e^{\frac{\lambda}{n}(\varphi_X(u)-1)}$ karakteristična funkcija slučajne spremenljivke $S_i = \sum_{i=1}^M X_i$ kjer je $M \sim \text{Pois}(\frac{\lambda}{n})$. □

Trditev 3.14. Naj bo S slučajna spremenljivka, ki zavzame vrednosti v \mathbb{N}_0 in je neskončno deljiva. Potem ima S sestavljeno Poissonovo porazdelitev.

Dokaz. Označimo rodovno funkcijo S z

$$G_S(u) = \sum_{k=0}^{\infty} \underbrace{\mathbb{P}(S = k)}_{p_k} u^k.$$

Pokazali bomo, da je $G_S(u)$ enaka rodovni funkciji neke slučajne spremenljivke, ki ima sestavljeno Poissonovo porazdelitev. Ker za nenegativne celoštevilске slučajne spremenljivke velja $\mathbb{P}(S = k) = \frac{G_S^{(k)}(0)}{k!}$, bo to pomenilo, da je S sestavljeno Poissonova, saj v tem primeru rodovna funkcija določa porazdelitev S . Ker je S neskončno deljiva potem je za vsak $n \in \mathbb{N}$

$$G_{S_n}(u) := (G_S(u))^{\frac{1}{n}} = \sum_{k=0}^{\infty} \underbrace{\mathbb{P}(S_n = k)}_{p_{k_n}} u^k$$

rodovna funkcija neke slučajne spremenljivke S_n in za vsak $u \in \mathbb{R}$ velja enakost

$$G_{S_n}(u) = (G_{S_1}(u))^n \text{ oziroma } \sum_{k=0}^{\infty} p_k u^k = \left(\sum_{k=0}^{\infty} p_{k_n} u^k \right)^n.$$

Če razširimo desno stran enače in predpostavimo $p_0 = 0$, dobimo, da bmora biti $p_{0_n} = 0$ in posledično tudi $p_1 = p_2 = \dots = p_{n-1} = 0$. Ker to velja za poljuben $n \in \mathbb{N}$ dobimo, da je $G_S(u) = 0$, kar pa je protislovje. Torej $p_0 > 0$ in zagotovo $G_S(u) > 0$ za $u \in [0, 1]$. Velja $\lim_{n \rightarrow \infty} \left(\frac{G_S(u)}{p_0} \right)^{\frac{1}{n}} = 1$ za $t \in [0, 1]$. Velja $\lim_{x \rightarrow 0} \frac{\ln(1+x)}{x} = 1$.

$$\ln \left(\left(\frac{G_S(u)}{p_0} \right)^{\frac{1}{n}} \right) = \ln \left(1 + \left(\left(\frac{G_S(u)}{p_0} \right)^{\frac{1}{n}} - 1 \right) \right) \approx \left(\frac{G_S(u)}{p_0} \right)^{\frac{1}{n}} - 1 \text{ ko } n \rightarrow \infty.$$

Za $u = 1$ dobimo

$$\ln \left(\left(\frac{1}{p_0} \right)^{\frac{1}{n}} \right) \approx \left(\frac{1}{p_0} \right)^{\frac{1}{p_0}} - 1 \text{ ko } n \rightarrow \infty.$$

□

Sedaj trditev 3.14 nadgradimo...

Trditev 3.15. *Naj ima slučajna spremenljivka S neskončno deljivo porazdelitev. Potem lahko S zapišemo izrazimo kot limito slučajni spremenljivk, ki imajo sestavljeno Poissonovo porazdelitev.*

Definicija 3.16. (Lévi jev proces) Naj bo $(X_t)_{t \geq 0}$ stohastični proces. Pravimo, da je $(X_t)_{t \geq 0}$ Lévi jev proces, če velja

- (1) $X_0 = 0$ skoraj gotovo,
- (2) $(X_t)_{t \geq 0}$ ima neodvisne prirastke,
- (3) $(X_t)_{t \geq 0}$ je stacionaren, torej ima enako porazdelitev za vsak $t \geq 0$.

4. CRAMÉR-LUNDBERGOV MODEL

Razdelek je prirejen po [3], [4] in [5].

V tem razdelku obravnavamo najbolj intenzivno raziskan model v teoriji propada, običajno imenovan Cramér-Lundbergov model. V svoji najosnovnejši obliki ga je v zgodnjih 1900. letih izpeljal švedski aktuar Filip Lundberg, da bi ocenil ranljivost zavarovalnice za propad. Čeprav je model v svoji ideji dokaj preprost, zajema bistvo povezave ravni rezerv zavarovalnice in njene izpostavljenosti tveganju, kar je razlog, zakaj je postal temeljni merilni model v teoriji propada. V preteklem stoletju je bilo razvitih veliko tehnik za analizo Cramér-Lundbergovega modela, ki so se večinoma osredotočale na kvantifikacijo verjetnosti propada zavarovalnice. V razdelku definiramo model in izpeljemo Lundbergovo neenakost ter asimptotično obnašanje verjetnosti propada v primeru, ko zavarovalniške zahteve modeliramo z lahkorepimi in težkorepimi porazdelitvami. V zgledih pokažemo, kako do rezultatov, ki nam jih zagotavlja teorija pridemo v praksi z Monte Carlo simulacijami procesa tveganja.

4.1. Proces tveganja in verjetnost propada.

Definicija 4.1. Naj bo $(S_t)_{t \geq 0}$ CPP, kjer so slučajne spremenljivke $(X_i)_{i \in \mathbb{N}}$, ki jih seštevamo s.g. nenegativne. *Proces tveganja* v Cramér-Lundbergovem modelu definiramo kot


$$U_t = u + p(t) - S_t,$$

kjer je $u \geq 0$ začetni kapital zavarovalnice in $p(t)$ funkcija prihodkov iz premij.

Opomba 4.2. V resnici lahko veliko lastnosti procesa tveganja izpeljemo brez da predpostavimo, da prihodi zahtevkov v $(S_t)_{t \geq 0}$ sledijo homogenem Poissonovemu procesu, ampak splošnem prenovitvenemu procesu (5.14). Zato bomo pri dokazovanju nekaterih rezultatov medprihodne čase zahtevkov T_i obravnavali v splošnem, brez da bi predpostavili, da so eksponentno porazdeljeni.

Vrednost U_t predstavlja kapital zavarovalnice ob času $t \geq 0$. Standardno je za $p(t)$ vzeti deterministično funkcijo $p(t) = ct$, kjer je $c > 0$ stopnja prihodkov premij. Uporaba linearne funkcije za modeliranje premijskega dohodka v Cramér-Lundbergovem modelu ponuja realističen približek zato, ker zavarovalnice pogosto doživljajo stabilno povečevanje premijskega dohodka skozi čas. Poleg tega je izbira linearne funkcije preprosta, zato bomo v nadaljevanju privzeli $p(t) = ct$. Poglejmo si realizaciji procesa tveganja, ko so zahtevki X_i porazdeljeni Weibullovo (5.2) z različnimi parametri.

Zgled 4.3. Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu z začetnim kapitalom $u = 1000$ in $p(t) = 200t$ ter intenzivnostjo prihodov zahtevkov $\lambda = 1$. Naj bodo v prvem primeru (rdeča) zahtevki porazdeljeni kot $X_i \sim \text{Weibull}(2, 434)$ in v drugem primeru (modra) kot $Y_i \sim \text{Weibull}(\frac{1}{4}, 16)$.



SLIKA 4. Realizaciji procesa tveganja

Pri obeh realizacijah vidimo, da proces tveganja v nekem trenutku pade pod 0 (tam ga tudi ustavimo). Čeprav je pričakova vrednost $\mathbb{E}[Y_i] = 384 \approx \mathbb{E}[X_i] = 217\sqrt{\pi} \approx 384,62$ opazimo bistveno razliko med realizacijama. V rdečem primeru proces pade pod 0 po več zaporednih manjših izgubah, v modrem primeru pa po eni zelo veliki izgubi. V nadaljevanju bomo primera ločili, ampak pred tem definirajmo osnovne pojme, ki jih bomo obravnavali v razdelku.

◇

Definicija 4.4. *Propad* definiramo kot dogodek, da proces tveganja $(U_t)_{t \geq 0}$ kadarkoli pade pod 0. Torej

$$\{U_t < 0 \text{ za } t \geq 0\}$$

in času ustavljanja

$$T = \inf\{t \geq 0 \mid U_t < 0\},$$

pravimo *čas propada*. Seveda velja enakost med dogodkoma

$$\{U_t < 0 \text{ za } t \geq 0\} = \{T < \infty\}.$$

Definicija 4.5. *Verjetnost propada* je definirana kot funkcija $\psi(u) : (0, \infty) \rightarrow [0, 1]$ podana s predpisom

$$\psi(u) = \mathbb{P}(T < \infty \mid U_0 = u).$$

Definicija 4.6. Po konstrukciji procesa tveganja $(U_t)_{t \geq 0}$ je verjetnost propada mogoča le ob prihodih zahtevkov. Z V_n označimo čas n -tega prihoda in definiramo ogrodje procesa tveganja kot $(U_{V_n})_{n \in \mathbb{N}}$.

Trditev 4.7. Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu in $(U_{V_n})_{n \in \mathbb{N}}$ njegovo ogrodje ter $T_n := V_n - V_{n-1}$ medprihodni čas n -tega zahtevka ($V_0 = T_0 = 0$). Potem velja

$$\psi(u) = \mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n > u \right),$$

kjer je $Z_n = \sum_{i=1}^n Y_i$ komulativna izguba po n prihodih in $Y_i = X_i - cT_i$ izguba i -tega prihoda.

Dokaz. S pomočjo ogrodja procesa tveganja lahko dogodek propada zapišemo kot

$$\begin{aligned} \{U_t < 0 \text{ za } t \geq 0\} &= \left\{ \inf_{t \geq 0} U_t < 0 \right\} \\ &= \left\{ \inf_{n \in \mathbb{N}} U_{V_n} < 0 \right\} \\ &= \left\{ \inf_{n \in \mathbb{N}} \{u + p(V_n) - S_{V_n}\} < 0 \right\} \\ &= \left\{ \inf_{n \in \mathbb{N}} \left\{ u + cV_n - \underbrace{\sum_{i=1}^n X_i}_{-Z_n} \right\} < 0 \right\} \\ &= \left\{ \inf_{n \in \mathbb{N}} \{-Z_n\} < -u \right\} \\ &= \left\{ \sup_{n \in \mathbb{N}} Z_n > u \right\}, \end{aligned}$$

kar nam da željeno enakost. □

Tako verjetnost propada prevedemo na prehodno verjetnost diskretnega slučajnega sprehoda $(Z_n)_{n \in \mathbb{N}}$. V nadaljevanju nas bo predvsem zanimalo asimptotično vedenje $\psi(u)$, ko gre $u \rightarrow \infty$. Cilj obravnavanja verjetnosti propada v Cramér-Lundbergovem modelu je, da se izognemo skoraj gotovemu propadu oziroma, da je verjetnost, da komulativna izguba $(Z_n)_{n \in \mathbb{N}}$ preseže u tako majhna, da lahko v praksi dogodek propada izključimo.

Trditev 4.8. Naj bo $(Z_n)_{n \in \mathbb{N}}$ zaporedje slučajnih spremenljivk definirano kot $Z_n = \sum_{i=1}^n Y_i$ za neodvisne in enako porazdeljene slučajne spremenljivke Y_i z $\mathbb{E}[Y_i] < \infty$. Če velja $\mathbb{E}[Y_i] \geq 0$, potem za vsak $u > 0$ velja

$$\mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n > u \right) = 1.$$

Dokaz. Zaporedje slučajnih spremenljivk $(Y_i)_{i \in \mathbb{N}}$ zadošča predpostavkam krepkega zakona velikih števil (5.6), torej velja

$$\frac{Y_1 + Y_2 + \cdots + Y_n}{n} = \frac{Z_n}{n} \xrightarrow[n \rightarrow \infty]{s.g.} \mathbb{E}[Y_n].$$

Torej bo Z_n v primeru ko je $\mathbb{E}[Y_n] > 0$ skoraj gotovo asimptotično linearno naraščal proti ∞ kot $\mathbb{E}[Y_n]n$ in bo za poljuben $u > 0$

$$\mathbb{P}\left(\sup_{n \in \mathbb{N}} Z_n > u\right) = 1.$$

Dokaz za primer, ko je $\mathbb{E}[Y_n] = 0$ je precej bolj tehničen in ne preveč informativen, zato ga bomo izpustili. Izkaže se, da obstajata neki podzaporedji $(n_k)_{k \in \mathbb{N}}$ in $(m_k)_{k \in \mathbb{N}}$, da $Z_{n_k} \xrightarrow[k \rightarrow \infty]{s.g.} \infty$ in $Z_{m_k} \xrightarrow[k \rightarrow \infty]{s.g.} -\infty$. Dokaz lahko najdemo v [6]. \square

Opomba 4.9. Iz trditve 4.8 (ob predpostavkah $\mathbb{E}[X_i] < \infty$ in $\mathbb{E}[T_i] < \infty$) sledi, da moramo premijo (in s tem c) izbrati tako, da bo $\mathbb{E}[Y_i] < 0$, saj bo tako $Z_n \xrightarrow[n \rightarrow \infty]{s.g.} -\infty$ in je to edini primer, ko lahko upamo, da verjetnost propada ne bo enaka 1.

Definicija 4.10. Pravimo, da proces tveganja $(U_t)_{t \geq 0}$ v Cramér-Lundbergovem modelu zadošča *pogoju neto zaslužka* (ang. *net profit condition*), če velja

$$c > \frac{\mathbb{E}[X_1]}{\mathbb{E}[T_1]}, \quad \text{oziroma} \quad c = (1 + \rho) \frac{\mathbb{E}[X_1]}{\mathbb{E}[T_1]} \quad \text{za } \rho > 0.$$

Pogoj bomo v nadaljevanju imenovali NPC.

Zahteva NPC za analizo poslovanja zavarovalnice je kar intuitivna, saj pove, da mora biti v nekem časovnem intervalu pričakovan dohodek iz premij večji od pričakovanega izplačila zahtevkov.

Definicija 4.11. Pravimo, da ima slučajna spremenljivka X *lahkorepo porazdelitev*, če za nek $\varepsilon > 0$ velja

$$\mathbb{E}[e^{uX}] = M_X(u) < \infty \quad \text{za } u \in (-\varepsilon, \varepsilon).$$

Sicer $M_X(u)$ obstaja le za $u \in (-\infty, 0]$ in pravimo, da ima X *težkorepo porazdelitev*.

Zgled 4.12 (Nadaljevnaje zgleda 4.3). V zgledu 4.3 smo obravnavali proces tveganja v Cramér-Lundbergovem modelu, kjer so zahtevki (rdeča) $X_i \sim \text{Weibull}(2, 434)$ in (modra) $Y_i \sim \text{Weibull}(\frac{1}{4}, 16)$. Opazili smo, da je v prvem primeru propad posledica več manjših izgub, v drugem pa ene velike izgube. To je značilnost težkorepih porazdelitev in za Weibullovo porazdelitev velja, da ima za parameter $a \geq 1$ lahek, za $a < 1$ pa težek rep.

Dokaz. Momentno rodovna funkcija $X \sim \text{Weibull}(a, b)$ je enaka

$$\begin{aligned} M_X(u) &= \int_0^\infty e^{ux} \frac{a}{b} \left(\frac{x}{b}\right)^{a-1} e^{-\left(\frac{x}{b}\right)^a} dx \quad \left(y = \frac{x}{b}, \quad dy = \frac{dx}{b}\right) \\ &= a \int_0^\infty e^{uby} y^{a-1} e^{-y^a} dy. \end{aligned}$$

Vidimo, da v 0 ni težav za poljuben $a > 0$, ampak za $a \in (0, 1)$ v neskončnosti funkcija divergira, saj se eksponent poenostavi v $y^a(uby^{1-a} - 1) \xrightarrow{y \rightarrow \infty} \infty$. Če v nadaljevanju predpostavimo $a \geq 1$ in uvedemo $z = y^a$ ($dz = ay^{a-1}dy$) pa lahko pridemo do lepe oblike za momentno rodovno funkcijo X .

$$M_X(u) = \int_0^\infty e^{ubz^{\frac{1}{a}}} e^{-z} dz$$

$$\begin{aligned}
&= \int_0^\infty \sum_{k=0}^\infty \frac{(ubz^{\frac{1}{a}})^k}{k!} e^{-z} dz && \text{Tonelli (5.10)} \\
&= \sum_{k=0}^\infty \frac{(ub)^k}{k!} \int_0^\infty z^{\frac{k}{a}} e^{-z} dz \\
&= \sum_{k=0}^\infty \frac{(ub)^k}{k!} \Gamma\left(\frac{k}{a} + 1\right).
\end{aligned}$$

◇

4.2. Lahkorepe porazdelitve. Od sedaj naprej bomo predpostavili, da je $(S_t)_{t \geq 0}$ v procesu tveganja $(U_t)_{t \geq 0}$ *CPP*. Najprej se bomo omejili na primer, ko ima porazdelitev slučajnih spremenljivk X_i , ki jih seštevamo v *CPP* lahek rep, saj je bila osnovna teorija, ki sta jo razvila Cramér in Lundberg, izpeljana pod to predpostavko.

4.2.1. *Lundbergova neenakost.*

Opomba 4.13. V praksi z lahkorepnimi porazdelitvami modeliramo zahtevke, kjer verjetnosti ekstremnih dogodkov (torej zelo velikih zahtevkov) eksponentno pada proti 0. To neposredno sledi iz definicije 4.11 in neenakosti Markova (5.5), saj za vsak $x > 0$ in $u \in (-\varepsilon, \varepsilon)$ velja

$$\mathbb{P}(X > x) = \mathbb{P}(e^{uX} > e^{ux}) \leq \frac{\mathbb{E}[e^{uX}]}{e^{ux}}.$$

Definicija 4.14. Naj velja, da ima slučajna spremenljivka $Y_1 = X_1 - cT_1$ iz trditve 4.7 lahek rep. Če obstaja enoličen $\ell > 0$ za katerega velja

$$M_{Y_1}(\ell) = 1,$$

potem ℓ pravimo *Lundbergov koeficient*.

Trditev 4.15. Če *Lundbergov koeficient* ℓ (pod predpostavkami definicije 4.14 in pogoja NPC) obstaja, potem je enolično določen.

Dokaz. Ker ima Y_1 lahek rep, obstaja $\varepsilon > 0$, da je $M_{Y_1}(u) < \infty$ za $u \in (-\varepsilon, \varepsilon)$. Ker velja $M_{Y_1}(0) = 1$ in $M'_{Y_1}(0) = \mathbb{E}[Y_1] < 0$ (zaradi pogoja NPC) ter $M''_{Y_1}(u) = \mathbb{E}[Y_1^2 e^{Y_1 u}] > 0$ ($Y_1 \neq 0$ skoraj gotovo) za $u > 0$, je $M_{Y_1}(u)$ zvezna konveksna funkcija na intervalu $(-\varepsilon, \varepsilon)$, kjer v okolici ničle pada. Po predpostavki obstaja $\ell > 0$, da je $M_{Y_1}(\ell) = 1$, ki pa je zaradi konveksnosti funkcije enolično določen. □

Izrek 4.16. (*Lundbergova neenakost*) Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC in naj zanj obstaja Lundbergov koeficient ℓ . Potem za vsak $u > 0$ velja

$$\psi(u) \leq e^{-\ell u}.$$

Dokaz. Neenakost bomo dokazali z indukcijo. Za $u > 0$ in $n \in \mathbb{N}$ definiramo

$$\psi_n(u) = \mathbb{P}\left(\max_{1 \leq k \leq n} Z_k > u\right)$$

in vidimo, da je (po zveznosti \mathbb{P} od spodaj) $\psi(u) = \lim_{n \rightarrow \infty} \psi_n(u)$, torej moramo pokazati, da za vsak $n \in \mathbb{N}$ velja $\psi_n(u) \leq e^{-\ell u}$.

($n = 1$): Uporabimo neenakost Markova in dobimo

$$\psi_1(u) = \mathbb{P}(e^{\ell Z_1} > e^{\ell u}) \leq \frac{M_{Z_1}(\ell)}{e^{\ell u}} = e^{-\ell u}.$$

($n \rightarrow n+1$): S F_{Y_1} označimo porazdeliltev Y_1 . Potem velja

$$\begin{aligned} \psi_{n+1}(u) &= \mathbb{P}\left(\max_{1 \leq k \leq n+1} Z_k > u\right) \\ &= \underbrace{\mathbb{P}(Y_1 > u)}_{(i)} + \underbrace{\mathbb{P}\left(\max_{2 \leq k \leq n+1} \{Y_1 + (Z_k - Y_1)\} > u, Y_1 \leq u\right)}_{(ii)} \end{aligned}$$

Najprej se posvetimo (ii). Po indukcijski predpostavki velja

$$\begin{aligned} (ii) &= \int_{(-\infty, u]} \mathbb{P}\left(\max_{1 \leq k \leq n} \{x + Z_k\} > u\right) dF_{Y_1}(x) \\ &= \int_{(-\infty, u]} \mathbb{P}\left(\max_{1 \leq k \leq n} Z_k > u - x\right) dF_{Y_1}(x) \\ &= \int_{(-\infty, u]} \psi_n(u - x) dF_{Y_1}(x) \\ &\stackrel{\text{I.P.}}{\leq} \int_{(-\infty, u]} e^{-\ell(u-x)} dF_{Y_1}(x). \end{aligned}$$

Za oceno (i) kot v primeru $n = 1$ uporabimo neenakost Markova in dobimo

$$(i) = \psi_1(u) \leq \frac{M_{Z_1}(\ell)}{e^{\ell u}} = \int_{(u, \infty)} e^{-\ell(u-x)} dF_{Y_1}(x).$$

Če torej seštejemo (i) in (ii) dobimo željeno oceno

$$\begin{aligned} \psi_{n+1}(u) &\leq \int_{\mathbb{R}} e^{-\ell(u-x)} dF_{Y_1}(x) \\ &= e^{-\ell u} M_{Y_1}(\ell) \\ &= e^{-\ell u}. \end{aligned}$$

□

Opomba 4.17. Iz izreka 4.16 je razvidno, da z dovolj visokim začetnim kapitalom u verjetnost propada lahko v praksi zadovoljivo omejimo blizu 0. Seveda je meja odvisna tudi od Lundbergovega koeficienta ℓ in krepko temelji na predpostavki lahkopredvidnih porazdelitev, ki pa v praksi pogosto niso izpolnjene.

Zgled 4.18. Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC. Naj nadalje velja da so zahtevki neodvisno eksponentno porazdeljeni s parametrom $\mu > 0$, torej $X_i \stackrel{\text{n.e.p.}}{\sim} \text{Exp}(\mu)$ za vsak i . Vemo, da ima momentno rodovna funkcija X_i obliko

$$M_{X_i}(u) = \frac{\mu}{\mu - u} \text{ za } u < \mu.$$

Tako dobimo, da ima momentno rodovna funkcija $Y_1 = X_1 - cT_1$ obliko

$$M_{Y_1}(u) = M_{X_1}(u)M_{T_1}(-cu) = \frac{\mu}{\mu - u} \frac{\lambda}{\lambda + cu} \text{ za } u \in (-\frac{\lambda}{c}, \mu).$$

Sedaj lahko izračunamo Lundbergov koeficient ℓ

$$\begin{aligned} M_{Y_1}(\ell) &= 1, \\ \frac{\mu}{\mu - \ell} \frac{\lambda}{\lambda + c\ell} &= 1, \\ \mu\lambda &= (\mu - \ell)(\lambda + c\ell), \\ \mu\lambda &= \mu\lambda - \ell\lambda + \mu c - c\ell^2, \\ 0 &= \mu c - c\ell - \lambda. \end{aligned}$$

Dobimo

$$\ell = \mu - \frac{\lambda}{c}. \quad (3)$$

Velja $\ell \in (0, \mu)$, saj v našem modelu velja pogoj NPC,

$$\frac{\mathbb{E}[X_1]}{\mathbb{E}[T_1]} = \frac{\lambda}{\mu} < c \iff \mu > \frac{\lambda}{c}.$$

Če uporabimo alternativno formulacijo NPC pogoja, dobimo

$$c = (1 + \rho) \frac{\lambda}{\mu} \Rightarrow \ell = \mu - \frac{\lambda}{(1 + \rho) \frac{\lambda}{\mu}} = \mu \left(\frac{\rho}{1 + \rho} \right). \quad (4)$$

Tako dobimo zgornjo mejo za verjetnost propada

$$\psi(u) \leq e^{-\ell u} = e^{-\mu u \left(\frac{\rho}{1 + \rho} \right)}$$

in vidimo, da povečanje stopnje prihodkov premij čez neko mejo ne bistveno vpliva na oceno, saj

$$\lim_{\rho \rightarrow \infty} e^{-\mu u \left(\frac{\rho}{1 + \rho} \right)} = e^{-\mu u}.$$

V nadaljevanju bomo videli, da je Lundbergova neenakost v primeru eksponentno porazdeljenih zahtevkov skoraj točna vrednost verjetnosti propada, zgrešena le za konstanto. V splošnem pa je zelo težko določiti Lundbergov koeficient kot funkcijo parametrov porazdelitev X_1 in T_1 in zato uporabljamo numerične metode za njegovo aproksimacijo kot na primer Monte Carlo simulacije. \diamond

4.2.2. Asimptotika verjetnosti propada. Sedaj se posvetimo vprašanju, kako se obnaša verjetnost propada v Cramér-Lundbergovem modelu, ko gre $u \rightarrow \infty$ in izpeljemo enega temeljnih rezultatov v teoriji tveganja.

Definicija 4.19. Za lažjo notacijo v nadaljevanju definiramo funkcijo *verjetnosti preživetja* kot $\theta(u) : (0, \infty) \rightarrow [0, 1]$ s predpisom

$$\theta(u) = \mathbb{P}(T = \infty \mid U_0 = u) = 1 - \psi(u).$$

Lema 4.20. (Integralska enačba za verjetnost preživetja) Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC in naj velja $\mathbb{E}[X_1] < \infty$ ter, da imajo slučajne spremenljivke $(X_i)_{i \in \mathbb{N}}$ gostoto. Potem $\theta(u)$ zadošča naslednji enakosti

$$\theta(u) = \theta(0) + \frac{1}{(1 + \rho)\mathbb{E}[X_1]} \int_{(0,u]} (1 - F_{X_1}(x))\theta(u - x)dx. \quad (5)$$

Dokaz. Po trditvi 4.7 velja

$$\psi(u) = \mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n > u \right),$$

kjer je $Z_n = \sum_{i=1}^n Y_i$ in $Y_i = X_i - cT_i$. Torej je

$$\begin{aligned} \theta(u) &= \mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n \leq u \right) \\ &= \mathbb{P} \left(\{Z_n \leq u \mid n \in \mathbb{N}\} \right) \\ &= \mathbb{P} \left(\{Y_1 \leq u\} \cap \{Z_n - Y_1 \leq u - Y_1 \mid n \geq 2\} \right) \\ &= \mathbb{E} \left[\mathbb{1}_{\{Y_1 \leq u\}} \mathbb{P} \left(\{Z_n - Y_1 \leq u - Y_1 \mid n \geq 2\} \mid Y_1 \right) \right]. \end{aligned}$$

Sedaj upoštevamo, da je $Y_1 = X_1 - cT_1$ in je torej dogodek $\{Y_1 \leq u\}$ enak dogodku $\{X_1 \leq u + cT_1\}$. Poleg tega velja, da je $(Z_n - Y_1)_{n \geq 2} \sim (Z_n)_{n \in \mathbb{N}}$, saj so Y_i neodvisne in enako porazdeljene slučajne spremenljivke. Upoštevamo še, da je T_1 medprihodni čas v $HPP(\lambda)$ da dobimo

$$\begin{aligned} \theta(u) &= \int_{(0,\infty)} \int_{(0,u+ct]} \mathbb{P} \left(\{Z_n \leq u - (x - ct) \mid n \in \mathbb{N}\} \right) dF_{X_1}(x) dF_{T_1}(t) \\ &= \int_{(0,\infty)} \int_{(0,u+ct]} \theta(u - x + ct) dF_{X_1}(x) \lambda e^{-\lambda t} dt. \end{aligned}$$

Uvedemo novo spremenljivko $z = u + ct$ (torej $t = \frac{z-u}{c}$ in $dt = \frac{dz}{c}$) in dobimo

$$\theta(u) = \frac{\lambda}{c} e^{\frac{\lambda u}{c}} \int_{(u,\infty)} e^{-\frac{\lambda z}{c}} \underbrace{\int_{(0,z)} \theta(z - x) dF_{X_1}(x)}_{g(z)} dz.$$

Ker ima porazdelitev F_{X_1} gostoto in je θ zvezna omejena funkcija, je funkcija $g(z)$ zvezna in jo lahko (po osnovnem izreku analize) odvajamo da dobimo

$$\theta'(u) = \frac{\lambda}{c} \theta(u) - \frac{\lambda}{c} \int_{(0,u)} \theta(u - x) dF_{X_1}(x).$$

Če sedaj obe strani integriramo po u dobimo

$$\int_{(0,t]} \theta'(u) du = \frac{\lambda}{c} \int_{(0,t]} \theta(u) du - \underbrace{\frac{\lambda}{c} \int_{(0,t]} \int_{(0,u]} \theta(u-x) dF_{X_1}(x) du}_{(i)}. \quad (6)$$

Na integralu (i) uporabimo per partes ($\alpha = \theta(u-x)$ in $d\beta = dF_{X_1}(x)$) ter upoštevamo, da ima F_{X_1} gostoto.

$$\begin{aligned} (i) &= (\theta(u-x)F_{X_1}(x)) \Big|_0^u + \int_{(0,u)} \theta'(u-x)F_{X_1}(x) dx \\ &= \theta(0)F_{X_1}(u) - \int_{(0,u)} \theta'(u-x)F_{X_1}(x) dx. \end{aligned}$$

Upoštevamo, da je $F_{X_1}(0) = 0$, saj je $X_1 > 0$ skoraj gotovo. Vstavimo (i) v (ii) in dobimo

$$(ii) = -\frac{\lambda}{c} \int_{(0,t]} \theta(0)F_{X_1}(u) du - \frac{\lambda}{c} \int_{(0,t]} \int_{(0,u]} \theta'(u-x)F_{X_1}(x) dx du.$$

Po Tonellijevem izreku (5.10) lahko zamenjamo vrstni red integracije.

$$\begin{aligned} (ii) &= -\frac{\lambda}{c} \int_{(0,t]} \theta(0)F_{X_1}(u) du - \frac{\lambda}{c} \int_{(0,t]} F_{X_1}(x) \int_{[x,t]} \theta'(u-x) du dx \\ &= -\frac{\lambda}{c} \int_{(0,t]} \theta(0)F_{X_1}(u) du - \frac{\lambda}{c} \int_{(0,t]} F_{X_1}(x) (\theta(t-x) - \theta(0)) dx. \\ &= -\frac{\lambda}{c} \int_{(0,t]} F_{X_1}(x) \theta(t-x) dx. \end{aligned}$$

Vstavimo (ii) v enačbo (6) in dobimo

$$\begin{aligned} \theta(t) - \theta(0) &= \frac{\lambda}{c} \int_{(0,t]} \theta(u) du - \frac{\lambda}{c} \int_{(0,t]} F_{X_1}(x) \theta(t-x) dx, \\ \theta(t) &= \theta(0) + \frac{\lambda}{c} \int_{(0,t]} (1 - F_{X_1}(x)) \theta(t-x) dx. \end{aligned}$$

Če sedaj upoštevamo enakost

$$\frac{\lambda}{c} = \frac{1}{1+\rho} \frac{1}{\mathbb{E}[X_1]}$$

in zamenjamo oznako spremenljivke $t \mapsto u$, dobimo željeno enakost (5). □

Opomba 4.21. Enačbo (5) lahko zapišemo tudi v obliki

$$\theta(u) = \theta(0) + \frac{1}{1+\rho} \int_{(0,u)} \theta(u-x) d\bar{F}_{X_1}(x), \quad (7)$$

kjer je \bar{F}_{X_1} porazdelitev integriranega repa (5.13) slučajne spremenljivke X_1 .

Opomba 4.22. Konstanto $\theta(0)$, ki se pojavi v (5) in (7) lahko izračunamo. Ker c zadošča NPC, analogno trditvi 4.8 velja

$$Z_n \xrightarrow[n \rightarrow \infty]{s.g.} -\infty.$$

Po zveznosti \mathbb{P} od spodaj sledi

$$\lim_{u \rightarrow \infty} \mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n \leq u \right) = \mathbb{P} \left(\sup_{n \in \mathbb{N}} Z_n \leq \infty \right) = 1.$$

Če torej v enačbi (7) pošljemo $u \rightarrow \infty$, dobimo

$$\lim_{u \rightarrow \infty} \theta(u) = 1 = \theta(0) + \frac{1}{1 + \rho} \lim_{u \rightarrow \infty} \int_{(0, \infty)} \mathbb{1}_{(0, u]}(x) \theta(u - x) d\bar{F}_{X_1}(x).$$

Po izreku o monotoni konvergenci (5.8) sledi

$$\begin{aligned} 1 &= \theta(0) + \frac{1}{1 + \rho} \int_{(0, \infty)} 1 d\bar{F}_{X_1}(x) \\ &= \theta(0) + \frac{1}{1 + \rho}. \end{aligned}$$

Torej je $\theta(0) = \frac{\rho}{1 + \rho}$. Enakost upoštevamo v enačbi (7) in dobimo

$$\theta(u) = \frac{\rho}{1 + \rho} + \frac{1}{1 + \rho} \int_{(0, u]} \theta(u - x) d\bar{F}_{X_1}(x). \quad (8)$$

Izrek 4.23. (*Asimptotika verjetnosti propada, lahkorepe porazdelitve*) Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC in naj zanj obstaja Lundbergov koeficient ℓ . Naj imajo slučajne spremenljivke $(X_i)_{i \in \mathbb{N}}$ gostoto. Potem obstaja konstanta $C > 0$ da velja

$$\lim_{u \rightarrow \infty} e^{\ell u} \psi(u) = C.$$

Dokaz. Najprej preoblikujemo enačbo (8), tako da upoštevamo $\theta = 1 - \psi$

$$\begin{aligned} 1 - \psi(u) &= \frac{\rho}{1 + \rho} + \frac{1}{1 + \rho} \int_{(0, u]} (1 - \psi(u - x)) d\bar{F}_{X_1}(x), \\ \psi(u) &= \frac{1}{1 + \rho} (1 - \bar{F}_{X_1}(u)) + \frac{1}{1 + \rho} \int_{(0, u]} \psi(u - x) d\bar{F}_{X_1}(x). \end{aligned}$$

Za lažjo notacijo uvedemo oznako $q = \frac{1}{1 + \rho}$ in dobimo

$$\psi(u) = q(1 - \bar{F}_{X_1}(u)) + \int_{(0, u]} \psi(u - x) d(q\bar{F}_{X_1}(x)). \quad (9)$$

Vidimo, da ima enačba (9) obliko prenovitvene enačbe (5.15) z bistveno razliko, da $q\bar{F}_{X_1}$ ni verjetnostna mera, saj velja $\lim_{x \rightarrow \infty} q\bar{F}_{X_1}(x) = q < 1$. Enačbi (9) pravimo defektna prenovitvena enačba. Za $x > 0$ definiramo funkcijo F_ℓ kot Esscherjevo transformacijo funkcije $q\bar{F}_{X_1}$.

$$F_\ell(x) = \int_{(0, x]} e^{\ell y} d(q\bar{F}_{X_1}(y)) = \frac{q}{\mathbb{E}[X_1]} \int_{(0, x]} e^{\ell y} (1 - F_{X_1}(y)) dy,$$

Pokažimo, da je F_ℓ porazdelitvena funkcija. Očitno je naraščajoča in velja

$$\begin{aligned}\lim_{x \rightarrow \infty} F_\ell(x) &= \frac{q}{\mathbb{E}[X_1]} \int_{(0, \infty)} e^{\ell y} (1 - F_{X_1}(y)) dy \quad (\alpha = 1 - F_{X_1}(y), \quad d\beta = e^{\ell y} dy) \\ &= \frac{q}{\mathbb{E}[X_1]} \left(\left(\frac{(1 - F_{X_1}(y)) e^{\ell y}}{\ell} \right) \Big|_0^\infty + \frac{1}{\ell} \int_{(0, \infty)} e^{\ell y} f_{X_1}(y) dy \right) \\ &= \frac{q}{\mathbb{E}[X_1]} \frac{1}{\ell} \left(\mathbb{E}[e^{\ell X_1}] - 1 \right).\end{aligned}$$

Sedaj upoštevamo, da je $q = \frac{1}{1+\rho} = \frac{\mathbb{E}[X_1]}{c\mathbb{E}[T_1]}$ in definicijo Lundbergovega koeficienta ter dejstvo, da je $T_1 \sim \text{Exp}(\lambda)$ medprihodni čas v HPP(λ), da dobimo

$$\begin{aligned}\lim_{x \rightarrow \infty} F_\ell(x) &= \frac{\mathbb{E}[e^{\ell X_1}] - 1}{c\ell \mathbb{E}[T_1]} \\ &= \frac{\frac{\lambda + c\ell}{\lambda} - 1}{c\ell \frac{1}{\lambda}} = 1.\end{aligned}$$

Če torej enačbo (9) pomnožimo z $e^{\ell u}$, dobimo

$$\begin{aligned}e^{\ell u} \psi(u) &= qe^{\ell u} (1 - \bar{F}_{X_1}(u)) + \int_{(0, u]} e^{\ell(u-x)} \psi(u-x) e^{\ell x} d(q\bar{F}_{X_1}(x)) \\ &= qe^{\ell u} (1 - \bar{F}_{X_1}(u)) + \int_{(0, u]} e^{\ell(u-x)} \psi(u-x) dF_\ell(x).\end{aligned}\tag{10}$$

Vidimo, da sedaj enačba (10) ustreza obliki $(qe^{\ell u} (1 - \bar{F}_{X_1}(u)), F_\ell)$ prenovitvene enačbe in ker je funkcija $qe^{\ell u} (1 - \bar{F}_{X_1}(u))$ omejena na končnih intervalih in F_ℓ ne-aritmetična, lahko uporabimo Smithov ključni prenovitveni izrek (5.18), da dobimo rešitev

$$e^{\ell u} \psi(u) = qe^{\ell u} (1 - \bar{F}_{X_1}(u)) + q \int_{(0, u]} e^{\ell(u-x)} (1 - \bar{F}_{X_1}(u-x)) dM^\ell(x), \tag{11}$$

kjer je M^ℓ prenovitvena mera prenovitvenega procesa z medprihodnimi časi, ki imajo porazdelitveno funkcijo F_ℓ . V splošnem težko določimo M^ℓ , ampak, če je $qe^{\ell u} (1 - \bar{F}_{X_1}(u))$ direktno Riemannovo integrabilna, nam Smithov izrek da asimptotično vedenje rešitve (11), ko gre $u \rightarrow \infty$. Direktno Riemannovo integrabilnost preverimo tako, da zapišemo

$$qe^{\ell u} (1 - \bar{F}_{X_1}(u)) = \int_0^u$$

Tako vidimo, da je $qe^{\ell u} (1 - \bar{F}_{X_1}(u))$ razlika dveh nenaraščajočih Riemannovo integrabilnih funkcij in je zato po kriteriju (5.17) direktno Riemannovo integrabilna. Dobimo

$$C = \lim_{u \rightarrow \infty} e^{\ell u} \psi(u) = \frac{q}{\alpha} \int_{(0, \infty)} e^{\ell x} (1 - \bar{F}_{X_1}(x)) dx, \tag{12}$$

kjer je $\alpha = \int_{(0, \infty)} x dF_\ell(x)$. S tem je izrek dokazan. \square

Opomba 4.24. Izrek 4.23 nam pove, da v primeru zahtevkov z lahkorepimi porazdelitvami verjetnost propada asimptotično točno eksponento pada proti 0 s tem ko začetni kapital u raste čez vse meje.

Zgled 4.25. (Nadaljevnaje zgleda 4.18) Vemo, da rešitve prenovitvene enačbe (11) iz izreka 4.23 v splošnem ne moremo izračunati. V zgledu 4.18 smo pa privzeli, da zahtevke modeliramo z eksponentno porazdelitvijo, torej $X_i \sim \text{Exp}(\mu)$. V tem primeru se izkaže, da lahko eksplicitno izračunamo verjetnost propada. Če si pogledamo enačbo (11), vidimo, da moramo izračunati le porazdelitev integriranega repa $\bar{F}_{X_1}(u)$ in prenovitveno mero Esscherjeve transformacije F_ℓ . Za eksponentno porazdelitev velja

$$\begin{aligned}\bar{F}_{X_1}(u) &= \frac{1}{\mathbb{E}[X_1]} \int_{(0,u)} (1 - F_{X_1}(t)) dt \\ &= \mu \int_{(0,u)} e^{-\mu t} dt \\ &= F_{X_1}(u),\end{aligned}$$

saj je pozabljiva. Prenovitveno mero Esscherjeve transformacije pa dobimo tako, da prvo izračunamo porazdelitveno funkcijo F_ℓ podano v enačbi (7).

$$\begin{aligned}F_\ell(u) &= \frac{q}{\mathbb{E}[X_1]} \int_{(0,u]} e^{\ell x} (1 - F_{X_1}(x)) dx \\ &= \frac{\mu}{1 + \rho} \int_{(0,u]} e^{-x(\mu - \ell)} dx.\end{aligned}$$

Upoštevamo rezultat (4), torej $\ell = \mu \left(\frac{\rho}{1 - \rho} \right)$ in vidimo, da je F_ℓ porazdelitvena funkcija eksponentne slučajne spremenljivke s paramterom $\frac{\mu}{1 + \rho}$ oziroma μq . Torej je prenovitvena mera $M^\ell(t)$ preprosto pričakovano število prihodov do časa t v HPP(μq), torej $M^\ell(t) = \mu q t$. Če vstavimo rezultata v enačbo (11) dobimo

$$\begin{aligned}e^{\ell u} \psi(u) &= q e^{\ell u} e^{-\mu u} + q \int_{(0,u]} e^{\ell(u-x)} e^{-\mu(u-x)} dM^\ell(x) \\ &= q e^{-u(\mu - \ell)} + \mu q^2 \int_{(0,u]} e^{-(\mu - \ell)(u-x)} dx \\ &= q e^{-u(\mu - \ell)} + \mu q^2 \frac{1}{\mu - \ell} \left(1 - e^{-u(\mu - \ell)} \right) \\ &= q e^{-u(\mu - \ell)} + \frac{\mu}{(1 + \rho)^2} \frac{1 + \rho}{\mu} \left(1 - e^{-u(\mu - \ell)} \right) \\ &= q e^{-u(\mu - \ell)} + q \left(1 - e^{-u(\mu - \ell)} \right) \\ &= q = \frac{1}{1 + \rho}.\end{aligned}$$

Končno dobimo, da je verjetnost propada enaka

$$\psi(u) = \frac{1}{1 + \rho} e^{-\ell u}. \quad (13)$$

◇

Vidimo, da se $\psi(u)$ z oceno, ki jo dobimo z Lundbergovo neenakostjo v zgledu 4.18 res razlikuje le za konstanto $\frac{1}{1+\rho}$. To je seveda zelo poseben primer, ko lahko vse količine izračunamo eksplicitno. Pokažimo kako bi do približkov funkcije $\psi(u)$ v praksi lahko prišli z Monte Carlo simulacijami.

Zgled 4.26. Kot v zgledu 4.18 predpostavimo, da so zahtevki porazdeljeni eksponentno, torej $X_i \sim \text{Exp}(\mu)$. Recimo, da je intenzivnost prihodov zahtevkov $\lambda = 1$, stopnja prihodkov premij $c = 1500$ in pričakovana vrednost zahtevkov 1000 €, torej $\mu = \frac{1}{1000}$. Potem lahko verjetnost propada eksplicitno izračunamo po formuli (13). Prvo izračunamo ρ po formuli (4), in ℓ po (3), torej

$$\begin{aligned}\rho &= \frac{c\mu}{\lambda} - 1 \\ &= \frac{1500 \cdot \frac{1}{1000}}{1} - 1 = \frac{1}{2}, \\ \ell &= \mu - \frac{\lambda}{c} \\ &= \frac{1}{1000} - \frac{1}{1500} = \frac{1}{3000}.\end{aligned}$$

Vsativmo vrednosti v (13) in dobimo

$$\psi(u) = \frac{2}{3}e^{-\frac{u}{3000}}.$$

Sedaj definiramo zaporedje $(u_n)_{n=1}^{50}$ s predpisom $u_n = 500n$ in za vsak n simuliramo 10, 50 in 100 realizacij procesa tveganja, bodisi do časa $T = 1000$ bodisi dokler ne propade in za vsak n izračunamo približek za verjetnost propada kot delež propadlih realizacij z vsemi. Aproksimacijo $\psi(u)$ prikažemo na sliki 5.



SLIKA 5. Aproksimacija verjetnosti propada $\psi(u)$ z Monte Carlo simulacijami.

Kot vidimo, se približki z naraščajocim številom simulacij priližujejo funkciji $\psi(u)$, ampak, za res dobro aproksimacijo, bi morali to število krepko povečati, saj na primer za vrednost $u = 16000$ je $\psi(16000) \approx 0.0032186334$, kar je približno 0.3% in v praksi ni zanemarljivo, ampak v naši simulaciji nobena realizacija procesa tveganja ni padla pod 0.

◇

4.3. Težkorepe porazdelitve. Rezultati, ki smo jih izpeljali v prejšnjem podpodglavju temeljijo na predpostavki zahtevkov z lahkorepimi porazdelitvami, kar interpretiramo, kot da je verjetnost zahtevkov, ki zelo odstopajo od povprečja zelo majhna. V praksi pa se pogosto zgodi, da ta predpostavka ni izpolnjena in pojavi se vprašanje, ali lahko še vedno kaj povemo o asimptotiki verjetnosti propada. Izkaže se, da v primeru, ko je porazdelitev integriranega repa zahtevkov subekspONENTNA, ta točno določa asimptotično vedenje verjetnosti propada. SubekspONENTNE porazdelitve so poseben razred težkorepkih porazdelitev.

Definicija 4.27. Naj bo $(X_i)_{i \in \mathbb{N}}$ zaporedje nenegativnih neodvisnih in enako porazdeljenih slučajnih spremenljivk s porazdelitveno funkcijo F za katero velja $F < 1$ za vsak $x > 0$. Pravimo, da je porazdelitev F *subekspONENTNA*, če velja

$$\lim_{x \rightarrow \infty} \frac{\mathbb{P}(X_1 + \dots + X_n > x)}{\mathbb{P}(X_1 > x)} = n \quad \text{za vsak } n \geq 2.$$

Opomba 4.28. Ekvivalentna in bolj intuitivna definicija subekspONENTNE porazdelitve je, da velja

$$\lim_{x \rightarrow \infty} \frac{\mathbb{P}(X_1 + \dots + X_n > x)}{\mathbb{P}(\max\{X_1, \dots, X_n\} > x)} = 1 \quad \text{za vsak } n \geq 2,$$

kar interpretiramo kot, da je repna porazdelitev vsote n -tih slučajnih spremenljivk primerljiva s porazdelitvijo največje. Dokaz ekvivalence lahko bralec najde v [9] na strani 437.

Izrek 4.29. (*Asimptotika verjetnosti propada, težkorepe porazdelitve*) Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC in naj bodo zahtevki $(X_i)_{i \in \mathbb{N}}$ neodvisni in enko porazdeljeni z gostoto f_X , pričakovano vrednostjo $\mathbb{E}[X] < \infty$ in naj bo \bar{F}_{X_1} subekspONENTNA. Potem za verjetnost propada $\psi(u)$ velja

$$\lim_{u \rightarrow \infty} \frac{\psi(u)}{1 - \bar{F}_{X_1}(u)} = \frac{1}{\rho}. \quad (14)$$

Dokaz. Najprej pokažimo, da lahko verjetnost preživetja iz leme 4.20 predstavimo kot sestavljeno geometrijsko porazdelitev (5.3). Če definiramo $G \sim \text{Geom}(\frac{\rho}{1+\rho})$ in zaporedje neodvisnih enako porazdeljenih slučajnih spremenljivk $(\bar{X}_i)_{i \in \mathbb{N}}$ s porazdelitveno funkcijo \bar{F}_{X_1} , se izkaže, da $C = \sum_{i=1}^G \bar{X}_i$ zadošča enačbi

$$\theta(u) = \frac{\rho}{1+\rho} + \frac{1}{1+\rho} \int_{(0,u]} \theta(u-x) d\bar{F}_{X_1}(x). \quad (8)$$

Porazdelitvena funkcija F_C ima obliko

$$\mathbb{P}(C \leq u) = \mathbb{P}(G = 0) + \sum_{n=1}^{\infty} \mathbb{P}(G = n) \mathbb{P}(\bar{X}_1 + \dots + \bar{X}_n \leq u)$$

$$= \frac{\rho}{1+\rho} + \frac{\rho}{1+\rho} \sum_{n=1}^{\infty} \frac{1}{(1+\rho)^n} \mathbb{P}(\bar{X}_1 + \dots + \bar{X}_n \leq u). \quad (15)$$

Za preglednost ponovno uvedemo oznako $q = \frac{1}{1+\rho}$ in $p = \frac{\rho}{1+\rho}$ in enačbo (15) preoblikujemo

$$\begin{aligned} \mathbb{P}(C \leq u) &= p + qp\bar{F}_{X_1}(u) + p \sum_{n=2}^{\infty} q^n \mathbb{P}(\bar{X}_1 + \dots + \bar{X}_n \leq u) \\ &= p + qp\bar{F}_{X_1}(u) + qp \sum_{n=2}^{\infty} q^{n-1} \int_{(0,u]} \mathbb{P}(x + \bar{X}_2 + \dots + \bar{X}_n \leq u) d\bar{F}_{X_1}(x) \\ &= p + q \int_{(0,u]} p \left[1 + \sum_{n=2}^{\infty} q^{n-1} \mathbb{P}(\bar{X}_2 + \dots + \bar{X}_n \leq u-x) \right] d\bar{F}_{X_1}(x) \\ &= p + q \int_{(0,u]} \mathbb{P}(C \leq u-x) d\bar{F}_{X_1}(x). \end{aligned}$$

Vidimo, da C zadošča enačbi (8) torej je res $\theta \sim C$. Limito $\lim_{u \rightarrow \infty} \frac{\psi(u)}{1-\bar{F}_{X_1}(u)}$ lahko tako zapišemo kot

$$\lim_{u \rightarrow \infty} \frac{\psi(u)}{1-\bar{F}_{X_1}(u)} = \lim_{u \rightarrow \infty} p \sum_{n=1}^{\infty} q^n \frac{\mathbb{P}(\bar{X}_1 + \dots + \bar{X}_n > u)}{1-\bar{F}_{X_1}(u)}.$$

Limito in vsoto lahko zamenjamo, saj če definiramo zaporedje funkcij ... Ker je \bar{F}_{X_1} subekspONENTNA, za $n \in \mathbb{N}$ velja

$$\lim_{u \rightarrow \infty} \frac{\mathbb{P}(\bar{X}_1 + \dots + \bar{X}_n > u)}{1-\bar{F}_{X_1}(u)} = n.$$

Končno

$$\lim_{u \rightarrow \infty} \frac{\psi(u)}{1-\bar{F}_{X_1}(u)} = p \sum_{n=1}^{\infty} q^n n = \frac{1}{\rho}.$$

□

Opomba 4.30. Pokažemo lahko tudi, da je C edina porazdelitev, ki zadošča (8) v razredu funkcij

$$\begin{aligned} \mathcal{F} = \{F \mid F : \mathbb{R} \rightarrow [0, \infty) \text{ omejena, nepadajoča, zvezna z desne} \\ \text{in za } x < 0 : F(x) = 0\}. \end{aligned}$$

Trditev sledi direktno iz lastnosti Laplace-Stiltjesove transformacije, saj lahko vsak $F \in \mathcal{F}$ zapišemo kot aF_X za primerno konstanto $a \geq 0$ in porazdelitveno funkcijo neke nenegativne skučajne spremenljivke X . Bolj podroben dokaz lahko bralec najde v [4] na strani 173.

Zgled 4.31. Naj bo $(U_t)_{t \geq 0}$ proces tveganja v Cramér-Lundbergovem modelu, ki zadošča NPC. Naj nadalje velja da so zahtevki neodvisno Weibullovo porazdeljeni s parametroma $a = \frac{1}{4}$ in $b = 16$, torej $X_i \sim \text{Weibull}(\frac{1}{4}, 16)$. Za dokaz, da je \bar{F}_{X_1} subekspONENTNA, lahko bralec pogleda [...]. Recimo, da je intenzivnost prihodov zahtevkov $\lambda = 1$ in stopnja prihodkov premij $c = 500$. Podobno kot v zgledu 4.26 z Monte Carlo simulacijami pokažimo, da verjetnost propada res pada proti 0 z

enakim redom konvergenca kot rep \bar{F}_{X_1} , ko gre $u \rightarrow \infty$. Porazdelitev integriranega repa \bar{F}_{X_1} ima obliko

$$\bar{F}_{X_1}(u) = \frac{1}{\mathbb{E}[X_1]} \int_{(0,u]} e^{-\left(\frac{x}{16}\right)^{\frac{1}{4}}} dx.$$


Iz zgleda 4.3 vemo, da je $\mathbb{E}[X_1] = 384$. Z uvedbo nove spremenljivke $z = x^{\frac{1}{4}}$ ($dz = \frac{1}{4x^{\frac{3}{4}}} dx$) z nekaj računanja dobimo

$$\bar{F}_{X_1}(u) = 1 - \frac{\left(u^{\frac{3}{4}} + 6\sqrt{u} + 24\sqrt[4]{u} + 48\right) e^{-\frac{\sqrt[4]{u}}{2}}}{48}$$

Izračunamo še

$$\rho = \frac{c\mathbb{E}[T_1]}{\mathbb{E}[X_1]} - 1 = \frac{500}{384} - 1 \approx 0.3020833.$$

Po izreku 4.29 razmerje $\frac{\psi(u)}{1-\bar{F}_{X_1}(u)}$ konvergira proti $\frac{1}{\rho} \approx 3.3103451$. Zaporedje $(u_n)_{n=1}^{50}$ definirano kot $u_n = 2000n$ za vsak n podobno kot v zgledu 4.26 simuliramo 10, 100 in 250 realizacij procesa tveganja in za vsak n izračunamo približek za razmerje $\frac{\psi(u_n)}{1-\bar{F}_{X_1}(u_n)}$. Rezultate prikažemo na sliki 6.



SLIKA 6. Aproksimacija verjetnosti propada $\psi(u)$ z Monte Carlo simulacijami (modra) in točna vrednost funkcije (rdeča).

Vidimo, da razmerje vizualno res konvergira proti $\frac{1}{\rho}$, ampak seveda bi za boljše natančnost morali povečati začetni kapital u in število simulacij. \diamond

5. PRILOGA

Dostavek je namenjen predvsem za dodatne definicije in trditve, ki so bile izpuščene v glavnem za namene preglednosti besedila. V primeru, da bralec potrebuje osvežiti določene pojme, jih večino lahko najde v tem razdelku.

Definicija 5.1. Naj bo X slučajna spremenljivka. Potem so za $u \in \mathbb{R}$ njena *rodovna funkcija*, *momentno rodovna funkcija* in *karakteristična funkcija* definirane kot

$$G_X(u) = \mathbb{E}[u^X], \quad M_X(u) = \mathbb{E}[e^{uX}], \quad \varphi_X(u) = \mathbb{E}[e^{iuX}],$$

če upanja obstajajo.

Definicija 5.2. Slučajna spremenljivka X ima *Weibullovo porazdelitev* s parametri $a, b > 0$, če ima njena porazdelitev obliko

$$F_X(x) = 1 - e^{-\left(\frac{x}{b}\right)^a} \quad \text{za } x \geq 0$$

in gostota obliko

$$f_X(x) = \left(\frac{a}{b}\right) \left(\frac{x}{b}\right)^{a-1} e^{-\left(\frac{x}{b}\right)^a} \quad \text{za } x \geq 0.$$

Definicija 5.3. Naj bo $(X_i)_{i \in \mathbb{N}}$ zaporedje neodvisnih enako porazdeljenih slučajnih spremenljivk in $G \sim \text{Geom}(p)$ geometrijsko porazdeljena slučajna spremenljivka parametrom $p \in (0, 1)$ in funkcijo verjetnosti $P(G = k) = p(1 - p)^k$ za $k \in \mathbb{N}_0$. Naj bo G neodvisna od X_i za vsak $i \in \mathbb{N}$. Potem pravimo, da ima slučajna spremenljivka

$$C = \sum_{i=1}^G X_i$$

sestavljeno geometrijsko porazdelitev.

Trditev 5.4. Naj bo X nenegativna slučajna spremenljivka na verjetnostnem prostoru $(\Omega, \mathcal{F}, \mathbb{P})$, ki ima prvi moment. Potem velja

$$\mathbb{E}[X] = \int_{(0, \infty)} (1 - F_X(x)) dx.$$

Dokaz. X lahko zapišemo kot

$$X = \int_{(0, \infty)} \mathbb{1}_{\{x < X\}} dx = \int_{(0, \infty)} \mathbb{1}_{\{X < x\}} dx.$$

Če sedaj uporabimo Fubinijev izrek dobimo

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E} \left[\int_{(0, \infty)} \mathbb{1}_{\{X < x\}} dx \right] \\ &= \int_{(0, \infty)} \mathbb{E} [\mathbb{1}_{\{X < x\}}] dx \\ &= \int_{(0, \infty)} (1 - \mathbb{P}(X > x)) dx \end{aligned}$$

□

Trditev 5.5. (Neenakost Markova) Naj bo X nenegativna slučajna spremenljivka. Potem za $x > 0$ velja

$$\mathbb{P}(X > x) \leq \frac{\mathbb{E}[X]}{x}.$$

Dokaz. Naj bo $x > 0$. Velja

$$x \mathbb{1}_{\{X > x\}} \leq X \iff x \mathbb{P}(X > x) \leq \mathbb{E}[X].$$

□

Izrek 5.6. (Krepki zakon velikih števil) Naj bo $(X_n)_{n \in \mathbb{N}}$ zaporedje neodvisnih enako porazdeljenih slučajnih spremenljivk na verjetnostnem prostoru $(\Omega, \mathcal{F}, \mathbb{P})$ s pričakovano vrednostjo $\mathbb{E}[X_i] = \mu < \infty$. Potem velja

$$\frac{X_1 + X_2 + \dots + X_n}{n} \xrightarrow[n \rightarrow \infty]{s.g.} \mu.$$

Dokaz. Dokaz izreka lahko bralec najde v [7].

□

Izrek 5.7. (Lévijev izrek o kontinuiteti) Naj bo $(X_n)_{n \in \mathbb{N}}$ zaporedje slučajnih spremenljivk (ne nujno na istem verjetnostnem prostoru) in X še ena slučajna spremenljivka. Potem za vsak $u \in \mathbb{R}$ velja

$$\varphi_{X_n}(u) \xrightarrow{n \rightarrow \infty} \varphi_X(u)$$

natanko tedaj, ko velja

$$X_n \xrightarrow[n \rightarrow \infty]{d} X.$$

Dokaz. Dokaz izreka lahko bralec najde v [7].

□

Izrek 5.8. (Lebesgueov izrek o monotoni konvergenci) Naj bo X_1, X_2, \dots zaporedje nenegativnih slučajnih spremenljivk na verjetnostnem prostoru $(\Omega, \mathcal{F}, \mathbb{P})$ in naj bo $X := \lim_{n \rightarrow \infty} X_n$ njihova limita. Naj za vsak $\omega \in \Omega$ velja $X_1(\omega) \leq X_2(\omega) \leq \dots$. Potem velja

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n\right] = \mathbb{E}[X].$$

Dokaz. Dokaz izreka lahko bralec najde v [7].

□

Izrek 5.9. (Lebesgueov izrek o dominirani konvergenci) Naj bo X_1, X_2, \dots zaporedje slučajnih spremenljivk na verjetnostnem prostoru $(\Omega, \mathcal{F}, \mathbb{P})$ in naj bo $X := \lim_{n \rightarrow \infty} X_n$ njihova limita. Naj bo Y slučajna spremenljivka definirana na istem verjetnostnem prostoru z $\mathbb{E}[Y] < \infty$ in naj za vsak $n \in \mathbb{N}$ in vsak $\omega \in \Omega$ velja $|X_n(\omega)| \leq Y(\omega)$. Potem je X integrabilna in velja

$$\lim_{n \rightarrow \infty} \mathbb{E}[X_n] = \mathbb{E}\left[\lim_{n \rightarrow \infty} X_n\right] = \mathbb{E}[X].$$

Dokaz. Dokaz izreka lahko bralec najde v [7].

□

Izrek 5.10. (Tonellijev izrek) Naj bosta X in Y slučajni spremenljivki definirani vsaka na svojem verjetnostnem prostoru in naj imata vsaka svojo gostoto f_X in f_Y glede na Lebesgueovo mero. Potem velja

$$\int_{\mathbb{R}^2} f_{X,Y}(x,y) \mathcal{L}^2(dx, dy) = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} f_{X,Y}(x,y) dx \right) dy = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} f_{X,Y}(x,y) dy \right) dx.$$

Dokaz. Dokaz izreka lahko bralec najde v [7]. □

Izrek 5.11. (Izrek o enoličnosti) One to one correspondence between characteristic functions and distributions.

Definicija 5.12. Naj bo X nenegativna slučajna spremenljivka in F_X njena porazdelitvena funkcija. Potem za $u \in \mathbb{R}$ Laplace-Stiltjesovo transformacijo porazdelitve F_X definiramo kot

$$\hat{F}_X(u) = \int_{[0,\infty)} e^{-ux} dF_X(x).$$

Definicija 5.13. Naj bo F porazdelitvena funkcija neke nenegativne slučajne spremenljivke s prvim momentom. Potem je

$$\bar{F}(x) = \frac{1}{\mathbb{E}[X]} \int_0^x (1 - F(t)) dt$$

porazdelitev integrarnega repa F .

Definicija 5.14. Prenovitveni proces na verjetnostnem protoru $(\Omega, \mathcal{F}, \mathbb{P})$ je slučajni proces karatkariziran z zaporedjem neodvisnih enako porazdeljenih medprihodnih časov $(T_n)_{n \in \mathbb{N}}$, ki zavzamejo vrednosti v $\mathbb{R}^+ \cup \{\infty\}$ in je podan z zvezo

$$N_t = \sum_{n=1}^{\infty} \mathbb{1}_{\{S_n \leq t\}},$$

kjer je $S_n = T_1 + T_2 + \dots + T_n$ čas n -tega prihoda. Pripadajočo prenovitveno mero prenovitvenega procesa definiramo kot $M(t) = \mathbb{E}[N_t]$ za $t > 0$.

Definicija 5.15. Prenovitvena enačba je enačba oblike

$$f(t) = g(t) + \int_{[0,t]} f(t-s) dF(s), \quad t \geq 0,$$

kjer sta neznana funkcija f in znana funkcija g definirani na \mathbb{R}^+ in F je porazdelitvena funkcija neke pozitivne slučajne spremenljivke X . Prenovitveno enačbo predstavimo s parom (g, F) .

Definicija 5.16. Za nenegativno merljivo funkcijo $f : [0, \infty) \rightarrow [0, \infty)$ pravimo, da je *direktno Riemannovo integrabilna* (d.R.i.), če za vsak $\delta > 0$ velja

$$\sum_{k \geq 0} \left(\sup_{t \in [k\delta, (k+1)\delta)} f(t) \right) < \infty \quad \text{in}$$

$$\lim_{\delta \downarrow 0} \delta \sum_{k \geq 0} \left(\sup_{t \in [k\delta, (k+1)\delta)} f(t) \right) = \lim_{\delta \downarrow 0} \delta \sum_{k \geq 0} \left(\inf_{t \in [k\delta, (k+1)\delta)} f(t) \right).$$

Če f zadošča navedenima zahtevama, potem je limita v drugi zahtevi točno vrednost direktnega Riemannovega integrala

$$\text{d.R.i.} \int_0^\infty f(t) dt.$$

Funkcija f poljubnega predznaka je d.R.i., če sta le-taki $f^+ = \max\{f, 0\}$ in $f^- = \max\{-f, 0\}$, pri čemer je

$$\text{d.R.i.} \int_0^\infty f(t) dt = \text{d.R.i.} \int_0^\infty f^+(t) dt - \text{d.R.i.} \int_0^\infty f^-(t) dt.$$

Trditev 5.17. (*Kriterij za direktno Riemannovo integrabilnost*) Naj bo $f \geq 0$ nenaščajóča funkcija. Potem je f direktno Riemannovo integrabilna natanko tedaj, ko je posplošeno Riemannovo integrabilna. Tedaj je njen direktni Riemannov integral enak posplošenemu.

Dokaz. Dokaz izreka lahko bralec najde v [8] na strani 235. □

Izrek 5.18. (*Smithov ključni prenovitveni izrek*) Če je funkcija g iz prenovitvene enačbe (g, F) (definicija 5.15) omejena na končnih intervalih in X ima prvi moment ter ni aritmetična ($\nexists a \in \mathbb{R} : \mathbb{P}(X \in \mathbb{Z}a) = 1$), potem je

$$f(t) = g(t) + \int_{[0,t]} g(t-s) dM(s), \quad t \geq 0,$$

enolična rešitev te enačbe. $M(s)$ je prenovitvena mera prenovitvenega procesa z medprihodno porazdelitvijo F . Če je dodatno funkcija g direktno Riemannovo integrabilna velja

$$\lim_{t \rightarrow \infty} f(t) = \frac{1}{\mathbb{E}[X]} \int_{(0,\infty)} g(t) dt.$$

Dokaz. Dokaz izreka lahko bralec najde v [8] na strani 237. □

SLOVAR STROKOVNIH IZRAZOV

trajektorija sample path
slučajni proces stochastic process
sestavljani Poissonov proces compound Poisson process
neskončna deljivost infinite divisibility
proces tveganja risk process
verjetnost propada probability of ruin
ogrodje procesa tveganja skeleton process
lahkorepa porazdelitev light-tailed distribution
težkorepa porazdelitev heavy-tailed distribution
subeksponentna porazdelitev subexponential distribution
prenovitveni proces renewal process
defektna prenovitvena enačba defective renewal equation
prenovitvena mera renewal function

LITERATURA

- [1] S.E. Shreve, Stochastic Calculus for Finance II: Continuous-Time Models, Springer, (2004).
- [2] S.M. Ross, Stochastic Processes: Second Edition, Wiley, (1996).
- [3] P. Embrechts, C. Klüppelberg, T. Mikosch, Modelling Extremal Events: For Insurance and Finance, Springer, (1997).
- [4] T. Mikosch, Non-Life Insurance Mathematics: An Introduction with the Poisson Process, Second Edition, Springer, (2009).
- [5] M. Mandjes, O. Boxma, The Cramér–Lundberg model and its variants, Springer, (2023).
- [6] F. Spitzer, Principles of Random Walk. Second Edition, Springer, (1976).
- [7] B. Fristedt, L. Gray, A Modern Approach to Probability Theory, Springer, (1996).
- [8] S.I. Resnick, Adventures in Stochastic Processes, Birkhäuser, (1992).
- [9] R.J. Adler, R.E. Feldman, A practical guide to heavy tails: statistical techniques and applications, Birkhäuser, (1998).